

2026 INNO CIM 存算一体高校挑战赛

赛道二 / 赛题二：3D 异构 CIM 资源调度优化

面向 MoE 大模型推理的 3D 异构 CIM 资源调度优化

设计报告

队名：_____ 待填写

成员：_____ 待填写

指导教师：_____ 待填写

完成日期： 2026 年 7 月 25 日

面向 MoE 大模型推理的 3D 异构 CIM 资源调度优化

摘要 面向 Mixture-of-Experts (MoE) 大模型推理, 3D 存算一体 (Computing-in-Memory, CIM) 资源的权重部署同时受到容量、空间互斥、依赖屏障和切换开销约束。本文实现一套面向赛题二的模型解析、Weight-Cube 切分、空间映射与静态调度一体化框架。该框架从激活轨迹提取专家共现、频率和转移统计, 以互斥分组、热点子图分配、局部搜索和自适应副本策略降低资源争用; 随后在 Sub-Cube 互斥、严格依赖、切换惩罚以及可选传输/计算重叠条件下生成可验证调度。以严格容量配置 $N = 3, D = 2, H = W = 4096$ 的平衡轨迹为例, 正式推荐的 V5 primary 方案将端到端模拟延迟从 539,729 cycles 降至 234,436 cycles, 降低 56.56%, 映射率为 1.0, 容量比为 1.9862。在 128 专家 metadata-only 大规模验证中, 优化方案获得 64,863 cycles 和 63.09% 的延迟降低。本文同时保留 solution.json、映射表、静态调度、运行清单和独立验证器, 便于复现与答辩核验。V5.1 的 231,672 cycles 结果仅作为官方激活轨迹到来前的增强候选, 不作为正式结论。

关键词 3D 存算一体; Mixture-of-Experts; 资源调度; 静态映射; Weight-Cube; 激活轨迹

Abstract This report presents an end-to-end 3D heterogeneous CIM scheduling framework for MoE-style inference. It combines model parsing, Weight-Cube partitioning, trace-aware placement, adaptive replication and static scheduling under capacity, exclusivity, dependency and switching constraints. On the balanced mock trace under a strict $N = 3, D = 2, H = W = 4096$ configuration, the formal V5 primary reduces simulated latency from 539,729 to 234,436 cycles (56.56%), with a mapping rate of 1.0 and a capacity ratio of 1.9862. The large-scale metadata-only experiment covers 128 experts and reports 64,863 cycles after optimization. All claims are bounded to the implemented simulator and supplied traces; the V5.1 result is retained as a candidate pending official-trace validation.

Key words 3D computing-in-memory; mixture of experts; resource scheduling; static mapping; activation trace

1 引言与问题定义

大模型推理中的参数访存与条件计算使传统“计算单元与存储单元分离”的组织方式面临带宽和容量压力。CIM 将权重驻留在计算邻近的存储阵列中, 为降低数据移动提供了硬件抽象; 但在多 Sub-Cube 的 3D 空间中, 权重块的物理位置又直接决定可并行度、切换次数和流水线等待。MoE 进一步放大了这一耦合: 路由专家仅在选门控选中时执行, 而共享专家或共享层具有稳定热点, 因而仅按模型拓扑或体积进行静态放置难以稳定降低排队代价。

MoE 通过稀疏路由以较低的单次计算量激活较大的参数集合, Switch Transformer 和 GShard 已展示了这一范式在大规模模型训练中的可扩展性 [1, 2]。DeepSeek-V3 的公开技术报告也体现出细粒度路由专家与共享专家并存的结构特征 [3]。这些工作说明, 专家访问模式不是独立同分布的随机噪声, 而是可由激活轨迹归纳的调度信息。

本项目聚焦赛题二而非完整的指令级编译器: 输入为 JSON 或受限 ONNX 元数据与 MoE 激活轨迹, 输出为权重空间映射和静态调度。目标是在固定的 3D CIM 资源配置内, 首先最小化端到端推理周期, 其次提升空间利用和大模型适配性; 输入输出格式与约束以赛题原文为准 [4]。本文的主要工作如下:

1. 建立模型解析、二维轴对齐 Weight-Cube 切分、轻量 JSON internal IR、映射和仿真的端到端可追溯链路;
2. 提出由共现、频率、burstiness 与转移统计驱动

的 MoE 分组与副本放置策略, 并结合热子图精确分配和局部搜索;

3. 实现考虑依赖屏障、Sub-Cube 互斥、切换、z 层访问、带宽和传输/计算重叠的静态调度模拟器, 以及独立提交校验器;
4. 给出严格容量下的主方案、候选方案、复制消融和 128 专家 metadata-only 压力验证, 并明确其数据与硬件模型边界。

2 工作原理与数学建模

2.1 3D 资源模型

整个 CIM 资源空间由 N^2 个相互独立的 Sub-Cube 构成。每个 Sub-Cube 的尺寸为 $D \times H \times W$, 其中 $N \in [2, 4]$, $H, W \in [4096, 16384]$, 而 D 由部署者设定。单个 Sub-Cube 的任意时刻仅允许激活一个 Weight-Cube, 不同 Sub-Cube 可并行执行, 但总并行数受配置上限约束。配置在一次模型部署期间保持静态, 符合权重驻留约束。

给定二维权重矩阵 $W \in \mathbb{R}^{m \times n}$, 解析器先以 H 为上界作水平切分, 再以 W 为上界作垂直切分。第 k 个 Weight-Cube 表示为 $C_k = (h_k, w_k, d_k)$, 本实现采用 $d_k = 1$ 的分层放置。该网格切分可由连续的水平与垂直切分构成, 不引入对角或旋转边界。

2.2 轨迹统计与优化目标

对包含 T 条推理记录的轨迹, 令 a_t 为第 t 次推理激活的专家集合。专家 i, j 的共现矩阵定义为

$$M_{ij} = \sum_{t=1}^T \mathbb{I}(i \in a_t \wedge j \in a_t). \quad (1)$$

当 $M_{ij} = 0$ 时, 二者可以作为共享同一 Sub-Cube 的互斥候选; 频率 $f_i = \sum_t \mathbb{I}(i \in a_t)$ 则用于识别热点专家。优化按优先级处理: 最小化端到端延迟 L , 最大化空间利用率 U_s , 并确保映射率 $R_m = 1$ 。其中

$$U_s = \frac{\sum_{p \in \mathcal{P}} \text{vol}(p)}{N^2 D H W}, \quad (2)$$

$\mathcal{P}$ 为成功放置的物理副本集合。复制必须同时满足几何无重叠与赛题容量比约束。

2.3 调度约束

对任务 q , 其开始时间 s_q 至少不小于所有前驱任务的完成时间; 若两个任务使用同一 Sub-Cube, 则其执行区间不得重叠。不同 Weight-Cube 在同一 Sub-Cube 上连续执行会产生切换惩罚, 较深 z 层引入额外访问代价。跨 Sub-Cube 依赖可按跨核传输惩罚参数计入传输开销; 当前正式实验的该参数为 0, 因此本文不将跨核传输延迟解释为已完成芯片标定。该模拟器定位为调度层的性能评估工具, 与加速器设计空间评估的通用思路一致 [5]。

3 系统结构与接口设计

图 1 展示了系统的数据流。解析器输出算子、依赖 DAG 与 Weight-Cube; 轨迹模块输出共现、频率、burstiness 和转移影响; 映射器生成物理放置及副本元数据; 模拟器生成静态 schedule 和性能指标; 验证器最终检查空间边界、重叠、调度互斥、依赖与映射率。各阶段均以 JSON 产物固化, 因而能够从最终 solution.json 回溯到输入哈希和配置。

输入模型采用算子级元数据表示, 支持线性、MoE 专家、MatMul/Gemm 与轻量非线性任务。ONNX 路径是 initializer-backed 结构适配, 不宣称覆盖完整 ONNX 执行语义。激活轨迹适配器接受顶层 traces、records 或 activations, 并统一单条记录的 active_experts、expert_ids、experts 与 topk_experts 字段, 为后续替换官方轨迹保留接口。

4 详细设计与实现

4.1 空间放置与副本管理

映射器提供 First Fit、Best Fit 和 aspect-aware 三类装箱策略。基线按顺序选择首个可用位置; 优化方案以 Best Fit 为主体, 通过剩余空间、形状碎片、分组一致性和已有负载选择候选位置。对于热点专家, 副本数由频率、争用、burstiness 和转移影响形成的压力得分决定, 并受到额外物理体积预算限制。副

本优先分散到不同 Sub-Cube, 以避免将逻辑副本重新聚集为同一资源瓶颈。

MoE 优化首先进行多起点互斥分组, 再按组需求和组间共现构造分配问题。热点组可在 top- k 范围内用分支定界精确分配, 剩余组采用局部迁移、交换和模拟退火改进。该过程并不替代物理装箱: 组分配只提供放置偏好, 最终仍由 3D 坐标可行性决定是否成功放置。

4.2 静态调度与约束验证

模拟器将每个推理实例展开为任务图。仅被轨迹激活的路由专家生成计算任务, 共享专家并入激活集合。就绪任务按照 FIFO 或关键路径优先策略选择候选物理副本; 调度器计算每个候选副本的依赖释放时间、Sub-Cube 空闲时间、切换惩罚、 z 层代价和带宽压力, 并选择最早可完成的方案。可选的线性或带宽/ z 感知非线性模型用于估计传输/计算重叠收益。

独立验证器不依赖模拟器内部状态, 检查 Weight-Cube 坐标边界、三维空间重叠、物理副本 ID 唯一性、schedule 与 placement 的 Sub-Cube 一致性、时间区间互斥、零长度任务、未放置 Cube 和映射率。运行清单记录输入 SHA-256、配置、运行环境与结果摘要, 形成可复现证据链。

5 优化策略与复杂度分析

5.1 策略设计

优化流程如图 2 所示。其核心不是仅提高单个专家的并发数, 而是在轨迹统计下权衡互斥性、热点副本、物理碎片与调度等待。共现低的专家可共享资源候选, 频率高且压力大的专家得到更多副本, 热点组优先分配到不同 Sub-Cube, 并将常用权重偏向低 z 层。该设计的收益应由具体轨迹验证; 它不是对任意模型与任意硬件的普适承诺。

5.2 复杂度

令 C 为 Weight-Cube 数, R 为 Shelf 行数, E 为专家数, G 为分组数, I 为局部搜索迭代数, S 为退火步数。ShelfPacker 的时间复杂度为 $O(CR)$; 多起点互斥分组约为 $O(TE^2G)$, 其中 T 是分组试验数; 热点子图精确分配最坏为 $O(N^k)$, 实际由 branch-and-bound 剪枝; 局部搜索为 $O(I(GN + G^2))$; 退火为 $O(SG^2)$ 。调度阶段对每个任务比较候选 placement 并使用优先队列维护就绪集, 复杂度约为 $O(Q(P + \log Q))$, 其中 Q 为任务数、 P 为候选物理副本数。

为避免搜索成本无界, 项目将精确求解限制在热点 top- k , 并提供并行多起点与确定性开关。实际提交参数将 k 固定为 6, 使 $N = 3$ 时的名义枚举上界为 9^6 ; 这使优化重点集中在最可能影响延迟的热点组。




图1 项目端到端部署与验证流程。




图2 轨迹感知映射与验证闭环。

6 实验设置与结果

6.1 设置与评价

正式主方案使用 `sample_model.json` 和由 `mock trace` 变体构成的平衡轨迹，Cube 配置为 $N = 3, D = 2, H = W = 4096$ ，最大并行 Sub-Cube 数为 9，并启用严格容量比 2.0。主方案使用 V5 参数卡中记录的重叠、搜索、复制、压缩和放置参数；所有输出由 `validate_submission.py` 再次检查。评价指标包括端到端延迟、空间利用率、时间利用率、切换代价、冲突分数、映射率和容量比。

6.2 主方案结果

表 1 给出 V5 primary 与 First Fit 基线的对比。优化方案将延迟降低 56.56%，同时将时间利用率由 0.2355 提升至 0.5431，切换代价从 15,576 降至 1,083 cycles。两者映射率均为 1.0。容量比 1.9862 小于严格上限 2.0，独立验证报告为 `ok=true` 且无错误。

6.3 复制消融与候选比较

在 V5 primary 的消融中，关闭复制后，优化延迟为 257,743 cycles，较基线降低 52.25%；完整配置为 234,436 cycles。这表明在该工作负载和参数设置下，副本预算对减少排队与气泡具有贡献。需要注意，当前 Best Fit 加 replication 消融与完整方案在该样例上得到相同延迟，因此该组结果不能单独证明互斥分组带来的边际收益；后续应补充 Best Fit only、分组 only、副本 only 与完整方案的正交消融。

V5.1 将专家副本预算提高至 0.35，同时关闭 shared/non-

expert operator replication。它得到 231,672 cycles (57.08%)，较 V5 primary 低 2,764 cycles，但空间利用率升至 0.6701，冲突分数升至 4.0。因此本文将其表述为候选，不替代正式 V5 primary。

6.4 大规模 metadata-only 验证

为验证工程链路在较多专家下仍能运行，使用脚本生成 128 专家、256 条推理、 $\text{top-}k = 4$ 的 metadata-only MoE 模型与轨迹，并采用 $N = 3, D = 8, H = W = 4096$ 。优化后延迟由 175,720 降至 64,863 cycles，降低 63.09%，映射率为 1.0，容量比为 1.9427。该实验只证明 parser、映射、调度与验证器在更大专家数量下可运行；它不等价于真实 DeepSeek-671B 权重部署或官方轨迹性能。

6.5 局限性与可复现性

截至本文完成时，正式评测激活轨迹尚未在本地项目中完成回归，因而所有性能数字受 mock/synthetic trace 分布约束。部分硬件惩罚参数为调度模型假设，未由芯片实测校准。ONNX 支持是元数据级轻量适配，未覆盖完整执行语义。尽管存在这些边界，项目保存了输入哈希、配置、映射、调度、内部 IR、可视化和验证报告；在当前代码版本上，项目虚拟环境回归测试记录为 30 passed。

7 总结

本文围绕赛题二的 3D 异构 CIM 资源调度问题，完成了从模型与轨迹解析、Weight-Cube 切分、共现感知映射到静态调度和独立验证的可运行链路。V5 primary 在严格容量约束下将平衡 mock trace 的模拟延迟降低 56.56%，并保持映射率 1.0；大规模 metadata-only 实验进一步说明链路可扩展到 128 专家。结果表明，将专家激活统计用于分组、副本与调度决策，能够在当前模拟设置中降低切换和流水线等待。

该结论的适用范围限定于项目的资源模型、mock/synthetic 轨迹和已记录的参数。下一步将以官方轨迹进行 parser smoke、主方案与 V5.1 候选的统一 replay，并结合可获得的 CIM 芯片文献或测量数据校准切换、z 层访问和跨 Sub-Cube 传输参数。

表 1 V5 primary 在平衡 mock trace 上的主结果。

方案	延迟 (cycles)	空间利用率	时间利用率	切换代价	冲突分数	映射率
First Fit 基线	539,729	0.5035	0.2355	15,576	6.0	1.0
V5 primary	234,436	0.5868	0.5431	1,083	2.0	1.0




图 3 同一平衡 mock trace 上的延迟对比。V5.1 仅为候选，尚需官方激活轨迹复核。

参考文献

- [1] William Fedus, Barret Zoph, and Noam Shazeer. “Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity”. In: *Journal of Machine Learning Research* 23.120 (2022), pp. 1–39.
- [2] Dmitry Lepikhin, Hyoungho Lee, Yuanzhong Xu, et al. “GShard: Scaling Giant Models with Conditional Computation and Automatic Sharding”. In: *International Conference on Learning Representations*. 2021.
- [3] DeepSeek-AI. *DeepSeek-V3 Technical Report*. 2024. arXiv: [2412.19437](https://arxiv.org/abs/2412.19437) [cs.CL].
- [4] 2026 INNO CIM 存算一体高校挑战赛赛道二赛题说明. 赛事官方 PDF, 项目随附文件《赛道 2.pdf》. 2026.
- [5] Angshuman Parashar, Priyanka Raina, Yakun Sophia Shao, et al. “Timeloop: A Systematic Approach to DNN Accelerator Evaluation”. In: *IEEE International Symposium on Performance Analysis of Systems and Software*. 2019, pp. 304–315.

团队介绍

队名：待填写。

成员与分工：待填写。建议在最终提交前补充每位成员的姓名、学校/院系、负责模块和联系方式。

开源与复现说明：代码工程、运行命令、参数卡、`solution.json`、`run_manifest.json` 和验证报告随作品压缩包一并提交。